Razão de chances: vaga A contra vaga B, no mesmo cardápio

Insper

$$P(A) \div P(B) = \exp(5 \cdot \beta) = 1{,}47\ [1{,}15;\ 1{,}89]$$

A e B	iguais em tudo no modelo; A paga +R$ 5 mil por mês
Não é	a chance de escolher A contra a de não escolher A
Na prática	≈ 107 vagas por candidato: a probabilidade sobe ≈ 47%

Fontes: VL_estimativas.csv (VL-1, ciclos 1–3; adendo 52e); doc 57x §1; auditoria 48.

O log está no modelo e no eixo, não na bolsa

$$\log[P(A) \div P(B)] = \beta \cdot \Delta bolsa;\ \ 5\beta = 0{,}385 \rightarrow \exp(0{,}385) = 1{,}47$$

IC	simétrico em log, 0,385 ± 0,25; exponenciado, [1,15; 1,89]
Eixo	em log: 0,5 e 2 ficam à mesma distância de 1
75 km	= 0,385 ÷ 0,514 × 100 km (peso da distância na mesma UF)

Fontes: VL_estimativas.csv (VL-1, ciclos 1–3: razão de chances, distancia_100km e K5); doc 57x §1 (VL-4).

Logit condicional: cada médico comparado consigo mesmo

$$V_{ij} = \beta \cdot bolsa_j + f(IVS_j) + \gamma \cdot dist_{ij} + \alpha_{par} + \ldots;$$
$$P_{ij} = \exp(V_{ij}) \div \Sigma_k \exp(V_{ik})$$

Estima	o β que maximiza Σ log P(vaga que cada um escolheu)
Cancela	tudo que é do médico: idade, nota, perfil
Erro-padrão	com cluster por conjunto de escolha (curso × ciclo): 55

Fontes: scripts/rdd_bolsa/25_escolha_dap.py (_estat, ajustar_cl); protocolo 52; adendo 52e; doc 57x.

Especificação principal: coeficientes do VL-1

Termo	Coeficiente (log-chance)	IC 95%	p
Bolsa (por R$ 1 mil/mês)	0,077	[0,027; 0,127]	0,002
IVS: inclinação	−0,170	[−0,410; 0,071]	0,166
IVS: dobra em 0,300	0,435	[0,085; 0,786]	0,015
IVS: dobra em 0,400	−0,426	[−0,724; −0,128]	0,005
Distância (por 100 km)	−0,514	[−0,555; −0,474]	< 0,001
Mesma região de saúde	1,103	[0,845; 1,361]	< 0,001
Mesmo município	0,587	[0,314; 0,860]	< 0,001
Tem vaga imediata	0,254	[0,043; 0,465]	0,018
log(vagas imediatas + 1)	0,491	[0,247; 0,734]	< 0,001
log(população 2022)	0,140	[0,081; 0,198]	< 0,001
Capital	−0,313	[−0,654; 0,028]	0,072
Interior remoto	−0,188	[−0,379; 0,003]	0,054
Metropolitano	0,104	[−0,050; 0,258]	0,186

Mais 254 dummies do par, não mostradas; estrato-base: interior perto de polo

Fontes: VL_estimativas.csv (VL-1, ciclos 1–3, tipo_linha = coeficiente); doc 57x §4.4; auditoria 48.

Referências do método

Papel	Referência
Estimador: logit condicional	McFadden (1974)
Olhar candidaturas, não só alocados	Dal Bó, Finan e Rossi (2013), *QJE*
Escolha de local de médicos no Brasil	Costa, Nunes e Sanches (2024), *REStat*
Logit do local em programa de provimento	Holmes (2005), *Labour Economics*
Inferência com poucos clusters	Kline e Santos (2012), score bootstrap

O efeito fixo do par vem do adendo 52e (pós-resultado), não de um artigo

Fontes: protocolo 40 (E9); docs 03_literatura_empirica/19 e 20; docs 42, 57x.

A base: uma linha por candidato × vaga do cardápio

Candidato	Vaga	Escolheu	Bolsa (mil)	Distância (100 km)	MG→SP	MG→BA
A (MG)	v1 em MG	0	10	1,2	0	0
A (MG)	v2 em MG	**1**	15	3,4	0	0
A (MG)	v3 em SP	0	10	5,1	1	0
A (MG)	v4 na BA	0	20	9,8	0	1
B (BA)	v1 em MG	0	10	11,0	—	—

Linhas ilustrativas. VL-1: 5.417 candidatos, 578.998 linhas, 55 conjuntos

Fontes: VL_resumo.json (identificacao, VL-1 ciclos 1–3); VL_estimativas.csv; scripts/rdd_bolsa/25_escolha_dap.py (montar_desenho).

De onde vem cada coluna da base

Ingrediente	Arquivo em output/	Unidade
Escolhas (1ª e 2ª opção)	outcomes/escolhas_candidatos.parquet	candidato × opção
Cardápio de vagas	outcomes/escolhas_conjunto_principal.parquet	CNES × curso × ciclo
Município de origem	G1_candidatos_origem.parquet	candidato (CNES pré)
Bolsa	aquisicao/a08 (IVS 2010 oficial)	município
Distância e região	centroides IBGE; CIR TabNet	origem × vaga

Nada é imputado: escolha fora do cardápio faz o script parar

Fontes: dicionario_outcomes_funil.json; scripts/rdd_bolsa/12, G1 e 25 (carregar, montar_desenho).

Efeito fixo do par: uma dummy por origem × UF da vaga

Candidato de MG	Candidato da BA
MG→MG = base	BA→BA = base
dummy MG→SP	dummy BA→SP
dummy MG→BA	dummy BA→MG

Absorve	apego à própria UF, atratividade do estado, macrorregião
Sobra	bolsa diferente dentro do par: 260 pares, 5.345 candidatos
Tamanho	729 → 281 pares com escolha; 254 dummies

Fontes: VL_resumo.json (identificacao, VL-1 ciclos 1–3); doc 57x §3 e decisões 1–3.

Fixo por construção ou controlado?

Item	Como entra	Fixo de fato?
Candidato	logit condicional: só compara as vagas dele	**sim**
Par de UFs	uma dummy por (origem, UF da vaga)	**sim**
Distância	controle linear: −0,514 por 100 km	**não**: controlada
Região e município	dummies de mesma região e mesmo município	**não**: controlados

Com log da distância: 1,45 [1,15; 1,83]; a leitura não muda

Fontes: VL_estimativas.csv (VL-1 e VL-1 com log da distância, ciclos 1–3); doc 57x §1 e decisão 4.

No código, o par é só mais uma coluna da matriz X

Insper

(a) rótulo do par e base 50_escolha_localizacao_par.py:525,540

```
par = pd.Series(o_lin, dtype=object) + "|" + pd.Series(v_lin, dtype=object)
propria = f"{o}|{uf_da_origem[o]}"
```

(b) tira o absorvido e cria as dummies 50_escolha_localizacao_par.py:616,619,621

```
X = X.drop(columns=[c for c in X.columns if c in ABSORVIDOS or c.startswith("macro_")])
Z = np.zeros((len(X), len(ef["nomes"])))
Z[np.flatnonzero(m), ef["col"][m]] = 1.0
```

(c) verossimilhança dentro de cada candidato 25_escolha_dap.py:490,493,494,495

```
v = X @ theta
S = np.add.reduceat(e, st)
p = e / S[grp]
ll_g = v[esc] - vmax - np.log(S)
```

Fontes: scripts/rdd_bolsa/50_escolha_localizacao_par.py (colunas_ef, matriz_vl); scripts/rdd_bolsa/25_escolha_dap.py (_estat); auditoria 48.

Perto do corte, o salto é medido contra outra reta

	Todas as vagas (VL-1)	Só ±0,050 do corte (VL-2)
Razão de chances (+R$ 5 mil)	1,47 [1,15; 1,89]	1,28 [0,95; 1,72]
Dobra da reta do IVS em 0,300	0,44	0,12
Dobra da reta do IVS em 0,400	−0,43	0,30
Candidatos	5.417	4.288

1,47 cabe no IC do VL-2: inconclusivo, não "efeito menor"

Fontes: VL_estimativas.csv (VL-1 e VL-2, ciclos 1–3); doc 57x §4; auditoria 48.