Razão de chances: vaga A contra vaga B, no mesmo cardápio

Insper

$$P(A) \div P(B) = \exp(5 \cdot \beta) = 1{,}47\ [1{,}15;\ 1{,}89]$$

A e B	iguais em tudo no modelo; A paga +R$ 5 mil por mês
Não é	a chance de escolher A contra a de não escolher A
Na prática	≈ 107 vagas por candidato: a probabilidade sobe ≈ 47%

Fontes: VL_estimativas.csv (VL-1, ciclos 1–3; adendo 52e); doc 57x §1; auditoria 48.

O log está no modelo e no eixo, não na bolsa

$$\log[P(A) \div P(B)] = \beta \cdot \Delta bolsa;\ \ 5\beta = 0{,}385 \rightarrow \exp(0{,}385) = 1{,}47$$

IC	simétrico em log, 0,385 ± 0,25; exponenciado, [1,15; 1,89]
Eixo	em log: 0,5 e 2 ficam à mesma distância de 1
75 km	= 0,385 ÷ 0,514 × 100 km (peso da distância na mesma UF)

Fontes: VL_estimativas.csv (VL-1, ciclos 1–3: razão de chances, distancia_100km e K5); doc 57x §1 (VL-4).

Logit condicional: cada médico comparado consigo mesmo

$$V_{ij} = \beta \cdot bolsa_j + f(IVS_j) + \gamma \cdot dist_{ij} + \alpha_{par} + \ldots;$$
$$P_{ij} = \exp(V_{ij}) \div \Sigma_k \exp(V_{ik})$$

Estima	o β que maximiza Σ log P(vaga que cada um escolheu)
Cancela	tudo que é do médico: idade, nota, perfil
Erro-padrão	com cluster por conjunto de escolha (curso × ciclo): 55

Fontes: scripts/rdd_bolsa/25_escolha_dap.py (_estat, ajustar_cl); protocolo 52; adendo 52e; doc 57x.

Especificação principal: coeficientes do VL-1

Termo	Coeficiente (log-chance)	IC 95%	p
Bolsa (por R$ 1 mil/mês)	0,077	[0,027; 0,127]	0,002
IVS: inclinação	−0,170	[−0,410; 0,071]	0,166
IVS: dobra em 0,300	0,435	[0,085; 0,786]	0,015
IVS: dobra em 0,400	−0,426	[−0,724; −0,128]	0,005
Distância (por 100 km)	−0,514	[−0,555; −0,474]	< 0,001
Mesma região de saúde	1,103	[0,845; 1,361]	< 0,001
Mesmo município	0,587	[0,314; 0,860]	< 0,001
Tem vaga imediata	0,254	[0,043; 0,465]	0,018
log(vagas imediatas + 1)	0,491	[0,247; 0,734]	< 0,001
log(população 2022)	0,140	[0,081; 0,198]	< 0,001
Capital	−0,313	[−0,654; 0,028]	0,072
Interior remoto	−0,188	[−0,379; 0,003]	0,054
Metropolitano	0,104	[−0,050; 0,258]	0,186

Mais 254 dummies do par, não mostradas; estrato-base: interior perto de polo

Fontes: VL_estimativas.csv (VL-1, ciclos 1–3, tipo_linha = coeficiente); doc 57x §4.4; auditoria 48.

Onde esse modelo é usado

Contexto	Estudo	Modelo
Professores, concurso com adicional por regra	Bobba et al. (2026), NBER WP 29068	logit multinomial, cardápio personalizado, coeficiente aleatório
Médicos, escolha de local no Brasil	Costa, Nunes e Sanches (2024), *REStat*	logit de coeficientes aleatórios
Médicos, programa de provimento (EUA)	Holmes (2005), *Labour Economics*	logit multinomial
Médicos, vagas hipotéticas (DCE)	Miranda et al. (2012); Kurniati et al. (2024)	logit condicional
Estimador	McFadden (1974)	logit condicional

O nosso é a versão mais simples da família; os mais parecidos usam variantes mais ricas

Fontes: Bobba et al., NBER WP 29068, rev. 22/01/2026, seção 4.1, eqs. 2, 5 e 6; doc 03_literatura_empirica/20 (A1, B5, C1, D3, D4); protocolo 40 §12.

Por que não um método mais simples?

Alternativa	O que compara	Por que não é a principal
RDD por vaga (nº de 1ªs opções)	vagas dos dois lados do corte	feita: IC contém zero; perde a variação dentro do candidato
MQO com efeito fixo do candidato	vagas do mesmo candidato, em p.p.	probabilidade ≈ 1% por vaga; fora do protocolo
Poisson das contagens com efeito fixo	vagas do mesmo cardápio e origem	dá o mesmo β do logit condicional

Trocar de estimador agora seria escolha pós-resultado: só como robustez

Fontes: doc 44 (F1.1); doc 57a §9 (P1g); Guimarães, Figueiredo e Woodward (2003), REStat 85(1).

A base: uma linha por candidato × vaga do cardápio

Candidato	Vaga	Escolheu	Bolsa (mil)	Distância (100 km)	MG→SP	MG→BA
A (MG)	v1 em MG	0	10	1,2	0	0
A (MG)	v2 em MG	**1**	15	3,4	0	0
A (MG)	v3 em SP	0	10	5,1	1	0
A (MG)	v4 na BA	0	20	9,8	0	1
B (BA)	v1 em MG	0	10	11,0	—	—

Linhas ilustrativas. VL-1: 5.417 candidatos, 578.998 linhas, 55 conjuntos

Fontes: VL_resumo.json (identificacao, VL-1 ciclos 1–3); VL_estimativas.csv; scripts/rdd_bolsa/25_escolha_dap.py (montar_desenho).

De onde vem cada coluna da base

Ingrediente	Arquivo em output/	Unidade
Escolhas (1ª e 2ª opção)	outcomes/escolhas_candidatos.parquet	candidato × opção
Cardápio de vagas	outcomes/escolhas_conjunto_principal.parquet	CNES × curso × ciclo
Município de origem	G1_candidatos_origem.parquet	candidato (CNES pré)
Bolsa	aquisicao/a08 (IVS 2010 oficial)	município
Distância e região	centroides IBGE; CIR TabNet	origem × vaga

Nada é imputado: escolha fora do cardápio faz o script parar

Fontes: dicionario_outcomes_funil.json; scripts/rdd_bolsa/12, G1 e 25 (carregar, montar_desenho).

Efeito fixo do par: uma dummy por origem × UF da vaga

Candidato de MG	Candidato da BA
MG→MG = base	BA→BA = base
dummy MG→SP	dummy BA→SP
dummy MG→BA	dummy BA→MG

Absorve	apego à própria UF, atratividade do estado, macrorregião
Sobra	bolsa diferente dentro do par: 260 pares, 5.345 candidatos
Tamanho	729 → 281 pares com escolha; 254 dummies

Fontes: VL_resumo.json (identificacao, VL-1 ciclos 1–3); doc 57x §3 e decisões 1–3.

Fixo por construção ou controlado?

Item	Como entra	Fixo de fato?
Candidato	logit condicional: só compara as vagas dele	**sim**
Par de UFs	uma dummy por (origem, UF da vaga)	**sim**
Distância	controle linear: −0,514 por 100 km	**não**: controlada
Região e município	dummies de mesma região e mesmo município	**não**: controlados

Com log da distância: 1,45 [1,15; 1,83]; a leitura não muda

Fontes: VL_estimativas.csv (VL-1 e VL-1 com log da distância, ciclos 1–3); doc 57x §1 e decisão 4.

No código, o par é só mais uma coluna da matriz X

Insper

(a) rótulo do par e base 50_escolha_localizacao_par.py:525,540

```
par = pd.Series(o_lin, dtype=object) + "|" + pd.Series(v_lin, dtype=object)
propria = f"{o}|{uf_da_origem[o]}"
```

(b) tira o absorvido e cria as dummies 50_escolha_localizacao_par.py:616,619,621

```
X = X.drop(columns=[c for c in X.columns if c in ABSORVIDOS or c.startswith("macro_")])
Z = np.zeros((len(X), len(ef["nomes"])))
Z[np.flatnonzero(m), ef["col"][m]] = 1.0
```

(c) verossimilhança dentro de cada candidato 25_escolha_dap.py:490,493,494,495

```
v = X @ theta
S = np.add.reduceat(e, st)
p = e / S[grp]
ll_g = v[esc] - vmax - np.log(S)
```

Fontes: scripts/rdd_bolsa/50_escolha_localizacao_par.py (colunas_ef, matriz_vl); scripts/rdd_bolsa/25_escolha_dap.py (_estat); auditoria 48.

Perto do corte, o salto é medido contra outra reta

	Todas as vagas (VL-1)	Só ±0,050 do corte (VL-2)
Razão de chances (+R$ 5 mil)	1,47 [1,15; 1,89]	1,28 [0,95; 1,72]
Dobra da reta do IVS em 0,300	0,44	0,12
Dobra da reta do IVS em 0,400	−0,43	0,30
Candidatos	5.417	4.288

1,47 cabe no IC do VL-2: inconclusivo, não "efeito menor"

Fontes: VL_estimativas.csv (VL-1 e VL-2, ciclos 1–3); doc 57x §4; auditoria 48.